

Parte I

Statistica Descrittiva

Capitolo 1

Definizioni Generali

Carattere

1.1

1.1.1 Qualitativo

Si parla di dati qualitativi quando la misurazione è fatta scegliendo un'etichetta a partire da un insieme di etichette disponibili. Le tipologie di dato qualitativo sono:

Nominale

- Sono dati che non posso confrontare e che non possiedono un ordine o categorie intrinseche.
- Colore dei capelli, categoria di prodotti e simili.

Binario o Booleano

- Sono un caso particolare dei dati a carattere nominale.
- Genere, vero o falso, assenza o presenza.

Ordinale

- Rappresentano caratteri che possono essere messi in relazione con operatori di $<$, $=$, $>$.
- Livelli di soddisfazione (basso, medio, alto), classifiche (primo, secondo, terzo) o risultati (triste, neutro, felice).

1.1.2 Quantitativo

Si parla di dati quantitativi se l'esito della misurazione è una quantità numerica. Inoltre:

- Sono scalari e sono caratteri quantitativi con un ordine definito e spesso hanno unità di misura.
- Altezza, peso, temperatura in gradi Celsius.

Infine, un carattere quantitativo può essere diviso in:

Discreto

- Tutti quei caratteri che ha senso rappresentare singolarmente.
- Data di nascita, oggetti venduti da un negozio e così via.

Continuo

- Tutti quei caratteri che ha senso rappresentare tramite un intervallo.
- Altezza, temperatura corporea, forza di un supereroe.

Popolazione

1.2

Insieme completo di oggetti. Esso è spesso troppo grande perché sia possibile un esame esaustivo. Per esempio i residenti di una regione oppure i televisori prodotti da un'azienda.

Campione

1.3

Un sottogruppo della popolazione, utile per apprendere informazioni dalla popolazione. Esso deve essere rappresentativo della popolazione.

$$C = \{x_1, \dots, x_n\} \quad (1)$$

1.3.1 Campione bivariato

Talvolta non abbiamo a che fare con sequenze di dati singoli, ma con sequenze di coppie di numeri, tra i quali esiste qualche relazione. In questi casi ogni coppia è da considerarsi un'osservazione. Possiamo denotare con (x_i, y_i) la coppia di valori ed essi prendono il nome di campione bivariato. Un esempio di campione bivariato potrebbe essere le ore di studio di uno studente e il suo punteggio all'esame.

1.3.2 Bias

Quando sei convinto di campionare bene la popolazione ma in realtà non lo stai facendo. Il bias è una tendenza a deviare dal valore atteso, introducendo distorsioni nei risultati di un esperimento.

Frequenza

1.4

1.4.1 Frequenza assoluta

Frequenza f con cui uno dei valori compare nel campione.

1.4.2 Frequenza relativa


Rapporto $\frac{f}{n}$ con cui la frequenza compare nel campione rispetto a l'insieme dei dati. Possiamo poi definire la media pesata come

$$\begin{aligned} \bar{x} &= \frac{1}{n} \sum_{j=1}^m v_j f_j \\ &= v_1 \frac{f_1}{n} + v_2 \frac{f_2}{n} + \dots + v_m \frac{f_m}{n} \end{aligned} \quad (2)$$

Classificatori

1.5

Considero un classificatore binario



Dentro al cerchio mettiamo le predizioni positive mentre il quadrato è il "mondo intero". In sostanza: se sto a sinistra o a destra del quadrato, sono sicuro. Se sono dentro al cerchio, posso essere VP o se sono nel quadrato a destra sono VN, quindi il predittore ha avuto ragione. FN è quando mi dice che è negativo ma è positivo nella realtà, FP è quando mi dice positivo ma è negativo. Qui sotto la *Matrice di Confusione*, dove con E è indicata l'etichetta e con P la predizione:

	+	E	-
+	VP		FP
P			
-	FN		VN
	TP		TN

L'**accuratezza**, compresa tra 0 e 1 è data da

$$\frac{VP + VN}{TP + TN}$$


Per la collettività, a volte, i FN hanno un peso maggiore sull'accuratezza (per esempio, se c'è una malattia, i FN sono liberi di uscire di casa come i VN ma i FN dovrebbero essere come i VP e FP). Dunque si usano la **sensibilità** e la **specificità**:

$$SENS = \frac{VP}{TP} = \frac{VP}{VP + FN}$$

$$SPEC = \frac{VN}{TN} = \frac{VN}{VN + FP}$$

Per essere più chiari usando l'esempio di tamponi per la rivelazione di un patogeno, il termine *sensibilità*, quando elevata, si riferisce alla capacità di trovare il patogeno anche se presente in piccole quantità sul tampone. Invece un tampone con elevata *specificità* è in grado di rilevare solo e soltanto quel patogeno, evitando di dare un falso positivo in caso un patogeno con RNA simile sia presente sul tampone. In particolare si può costruire un grafico a partire da

$$(1 - SPEC, SENS) = \left(1 - \frac{VN}{TN}, \frac{VP}{TP}\right) = \left(\frac{FP}{TN}, \frac{VP}{TP}\right) = \left(\frac{FP}{FP + VN}, \frac{VP}{VP + FN}\right)$$



- **Classificatore Costante Positivo:** CP becca correttamente i casi positivi ma non azzecca alcun caso negativo

$$SENS = \frac{VP}{TP} = 1, SPEC = \frac{0}{TN} = 0$$

	+	E	-
+	TP		TN
P			
-	0		0

- **Classificatore Costante Negativo:** CN è l'opposto di CP

$$SENS = \frac{0}{TP} = 0, SPEC = \frac{VN}{TN} = 1$$

	+	E	-
+	0		0
P			
-	TP		TN

- **Classificatore Ideale:** CI non sbaglia mai

$$\text{SENS} = \frac{VP}{TP} = 1, \text{ SPEC} = \frac{VN}{TN} = 1$$

	+	E	-
+	TP		0
P			
-	0		TN

- **Classificatore Sbagliato:** CS sbaglia sempre

$$\text{SENS} = \frac{0}{TP} = 0, \text{ SPEC} = \frac{0}{TN} = 0$$

	+	E	-
+	0		TN
P			
-	TP		0

- **Classificatore Casuale:** $CC_{1/2}$ lancio della moneta e $CC_{4/5}$ dado a 5 facce

$$\text{SENS} = \frac{1}{2}, \text{ SPEC} = \frac{1}{2}$$

	+	E	-
+	$\frac{1}{2}$ TP		$\frac{1}{2}$ TN
P			
-	$\frac{1}{2}$ TP		$\frac{1}{2}$ TN

$$\text{SENS} = \frac{4}{5}, \text{ SPEC} = \frac{1}{5}$$

	+	E	-
+	$\frac{4}{5}$ TP		$\frac{4}{5}$ TN
P			
-	$\frac{1}{5}$ TP		$\frac{1}{5}$ TN

1.5.1 Curva ROC

Più ci si avvicina a CI e meglio è, dunque si osserva la curva ROC (*Receiver Operating Characteristic*). Tuttavia, guardare la curva ROC da sola è un giudizio qualitativo, dunque osservo l'area sottesa a ROC ossia la AUC.

1.5.2 AUC

L'*Area Under the roc Curve* è l'area sottesa alla curva ROC. Essa è $0 \leq \text{AUC} \leq 1$ e raggiunge 1, area del quadrato ($1^2 = 1$) nel caso in cui la ROC vada subito a CI e non si muova da quella posizione.

