

Capitolo 2

Indici

Indici di centralità

2.1

2.1.1 Media Campionaria

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

La media campionaria è un indice di centralità ed è definita come il "baricentro dei dati". Dalla media campionaria si può arrivare al concetto di **scarto** dimostrando che

$$\begin{aligned} \sum_{i=1}^n (x_i - \bar{x}) &= \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \\ &= n\bar{x} - n\bar{x} \\ &= 0 \end{aligned} \quad (2)$$

La media campionaria rimane poco robusta rispetto agli outliers.

2.1.2 Mediana Campionaria

- Ordino il campione in ordine crescente
- Seleziono il valore m tale che:

$$m = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } |C| \text{ è dispari} \\ \frac{[x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}]}{2} & \text{se } |C| \text{ è pari} \end{cases} \quad (3)$$

Quindi nel caso dispari seleziono il valore che si trova al centro seguendo l'ordine crescente, mentre nel caso pari faccio la media aritmetica tra i due valori centrali. Se mi capita di avere elementi non scalari e dunque non divisibili, posso riportarli entrambi o sceglierne uno dei due.

2.1.3 Moda Campionaria

Definito come il dato che si presenta più spesso nel campione (caso unimodale). Se mi capita di avere due o più valori con la stessa frequenza (caso multimodale), posso riportare entrambi i valori modali o sceglierne uno dei due, come nella mediana campionaria.

2.2.1 Quantile campionario

Possiamo definire la mediana campionaria come il valore del campione che è $\geq$ almeno il 50% dei dati e $\leq$ almeno il 50% dei dati. Generalizzando questo concetto si può introdurre il quantile campionario di livello $q \in [0, 1]$, ossia il valore del campione $\geq$ almeno il $100 \cdot q\%$ dei dati e $\leq$ almeno il $100 \cdot (1 - q)\%$ dei dati.

Per esempio, immagino di avere 12 osservazioni e voglio trovare il quantile $q = 0.9$

$$x_1 \ x_2 \ x_3 \ x_4 \ x_5 \ x_6 \ x_7 \ x_8 \ x_9 \ x_{10} \ x_{11} \ x_{12} \quad (4)$$

Evidenziamo il valore $\geq 90\%$ di $12 = 10.8 = 11$

$$x_1 \ x_2 \ x_3 \ x_4 \ x_5 \ x_6 \ x_7 \ x_8 \ x_9 \ x_{10} \ \underline{x_{11}} \ x_{12} \quad (5)$$

Evidenziamo il valore $\leq 10\%$ di $12 = 1.2 = 2$

$$\underline{x_1 \ x_2 \ x_3 \ x_4 \ x_5 \ x_6 \ x_7 \ x_8 \ x_9 \ x_{10} \ x_{11} \ x_{12}} \quad (6)$$

Sovrapponiamoli

$$x_1 \ x_2 \ x_3 \ x_4 \ x_5 \ x_6 \ x_7 \ x_8 \ x_9 \ x_{10} \ \underline{x_{11}} \ x_{12} \quad (7)$$

x_{11} è il quantile che cercavo. Se invece io mi trovo ad avere dei quantili con valori interi, come per esempio nel caso di $n = 20$ e $q = 0.95$, dove x_{19} e x_{20} sono entrambi risultati, allora eseguo la media aritmetica tra i due

$$\frac{x_{19} + x_{20}}{2} \quad (8)$$

Se cambio la scala, il procedimento resta lo stesso e i quantili assumono nomi specifici. Per scale $[0 - 100]$ prendono il nome di *percentili*, per scale $[0 - 10]$ invece *decili* e infine i *quartili* per scale $[0 - 4]$. A proposito di quartili, definiamo con *range interquartile (IQR)* la differenza tra il terzo e il primo quartile.

Riassumendo, nel caso specifico dei quartili, la mediana risulta essere il secondo quartile (Q2), mentre il valore minimo e il valore massimo sono rispettivamente $Q1 - (1.5 \cdot IQR)$ e $Q3 + (1.5 \cdot IQR)$.

2.2.2 Varianza campionaria

Vogliamo osservare quanto i dati siano dispersi o concentrati, per farlo potremmo giudicare dalla loro distanza in modulo $|x_i - \bar{x}|$. Tuttavia non vogliamo usare il valore assoluto per togliere i valori negativi perché è scomodo lavorare con il valore assoluto, dunque eleviamo al quadrato $(x_i - \bar{x})^2$. Facciamo questo procedimento per ogni elemento del campione e dividiamo così da ottenere

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (9)$$

In particolare possiamo osservare che

$$\begin{aligned} \sum_i (x_i - \bar{x})^2 &= \sum_i (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \\ &= \sum_i x_i^2 - \sum_i 2\bar{x}x_i + \sum_i \bar{x}^2 \\ &= \sum_i x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\ &= \sum_i x_i^2 - n\bar{x}^2 \end{aligned} \quad (10)$$

E dunque possiamo riscrivere la varianza campionaria come

$$\frac{1}{n-1} \left(\sum_i x_i^2 - n\bar{x}^2 \right) \quad (11)$$

Alcune proprietà della varianza rispetto alle trasformazioni:

- **Traslazione:** $\bar{y} = \bar{x} + b$

$$\begin{aligned} s_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (x_i + b - \bar{x} - b)^2 \\ &= s^2 \end{aligned} \quad (12)$$

- **Scalatura:** $y_i = \alpha x_i$

$$\begin{aligned} s_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (\alpha x_i - \alpha \bar{x})^2 \\ &= \alpha^2 s^2 \end{aligned} \quad (13)$$

2.2.3 Deviazione standard campionaria

Quando usiamo la varianza campionaria abbiamo problemi con le unità di misura che sono tutte elevate al quadrato rispetto al normale, dunque definiamo la deviazione standard campionaria come

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (14)$$

N.B. rispetto alle operazioni di scalatura vale che $s_y = |\alpha| s_x$

2.2.4 Coefficiente di variazione

Siccome la varianza assume importanza inversamente proporzionale rispetto all'ordine di grandezza può aver senso "standardizzarla" rispetto alla media campionaria:

$$s^* = \frac{s}{|\bar{x}|} \quad (15)$$

Nel caso in cui ci siano sia valori positivi che negativi, basta effettuare una opportuna traslazione del campione per far sì che tutte le osservazioni abbiano segno concorde. Il coefficiente di variazione risulta particolarmente utile in situazioni in cui vogliamo confrontare la variabilità di distribuzioni che presentano scale di grandezza distinte.

2.2.5 Covarianza campionaria

Preso un campione bivariato, definiamo

$$Cov(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (16)$$

Se il risultato è ≥ 0 allora esiste una correlazione diretta tra i dati, indiretta se < 0 . Quindi se ho due campioni di cardinalità n , voglio determinare se sono correlati; un esempio di correlazione diretta può essere

$$x_i \text{ piccolo} \iff y_i \text{ piccolo} \wedge x_i \text{ grande} \iff y_i \text{ grande}$$

2.3.1 Coefficiente di correlazione campionaria

Dato un campione bivariato si dice coefficiente di correlazione campionaria e si denota con r la quantità

$$r = \frac{1}{n-1} \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{s_x s_y} \quad (17)$$

Questo coefficiente gode delle seguenti proprietà:

- (1) $-1 \leq r \leq 1$, con relazione diretta per $r = 1$, indiretta per $r = -1$ e indefinita per $r = 0$. Questo è dimostrabile tramite i seguenti passaggi: considerando $y_i = a + bx_i$ e dunque $\bar{y} = a + b\bar{x}$, $s_y = |b| s_x$ e $y_i - \bar{y} = a + bx_i - a - b\bar{x} = bx_i - b\bar{x}$. Possiamo quindi dedurre che

$$\begin{aligned} r &= \frac{1}{n-1} \frac{b \sum_{i=1}^n (x_i - \bar{x})^2}{s_x |b| s_x} \\ &= \frac{b}{|b|} \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \frac{1}{s_x^2} \\ &= \frac{b}{|b|} \\ &= \text{sign}(b) \end{aligned} \quad (18)$$

- (2) Se r è il coefficiente di correlazione del campione (x_i, y_i) , allora lo è anche per il campione $(a + bx_i, c + dy_i)$ purché b e d abbiano lo stesso segno. Ossia il coefficiente di correlazione del campione non cambia se sommiamo costanti o moltiplichiamo per costanti: ciò significa che r non dipende dalle unità di misura.

2.3.2 Coefficiente di correlazione di Pearson

Considerando che

$$\begin{aligned} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n \bar{x} y_i - \sum_{i=1}^n x_i \bar{y} + \sum_{i=1}^n \bar{x} \bar{y} \\ &= \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} \\ &= \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \end{aligned} \quad (19)$$

allora possiamo riscrivere r come

$$\begin{aligned} r &= \frac{1}{n-1} \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\frac{1}{n-1} \sqrt{\sum_{i=1}^n x_i^2 - n\bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n\bar{y}^2}} \\ &= \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sqrt{\sum_{i=1}^n x_i^2 - n\bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n\bar{y}^2}} \end{aligned} \quad (20)$$

2.4.1 Eterogeneità

Un campione omogeneo è tale quando ogni elemento è uguale, mentre un campione eterogeneo è chiamato così quando vi sono le stesse frequenze per ogni valore del campione. Per esempio il seguente campione è omogeneo



il seguente è eterogeneo



mentre quest'ultimo non è né omogeneo né eterogeneo



2.4.2 Indice di Gini

Nel caso in cui stessimo studiando la distribuzione di un attributo di una popolazione (ad esempio la ricchezza), potresti dover discernere tra una distribuzione equa ed una non equa. Posso usare l'indice di Gini che è un indice per l'eterogeneità ed è indicato come

$$I = 1 - \sum_{j=1}^k f_j^2 \quad (21)$$

definito $\forall j \ 0 \leq f_j \leq 1$, ma che valori può assumere I ?

Analizziamo prima per $\forall j \ f_j \geq 0$

$$(1) \sum_{j=1}^k f_j = 1$$

$$(2) \exists j' \ f_{j'} : f_{j'}^2 > 0 \implies \sum_{j=1}^k f_j^2 > 0$$

$$(3) I = 1 - \sum_{j=1}^k f_j^2 \implies I < 1$$

Ora analizziamo per $\forall j \ 0 \leq f_j \leq 1$

$$(1) f_j^2 \leq f_j$$

$$(2) \sum_{j=1}^k f_j^2 \leq \sum_{j=1}^k f_j = 1 \implies 1 - \sum_{j=1}^k f_j^2 \geq 0 \implies I \geq 0$$

Dunque possiamo asserire che

$$0 \leq I < 1$$

Facciamo degli esempi:

Eterogeneità Minima: Supponendo di avere  ci ritroviamo  con frequenza relativa $f = 1$, dunque

$$\begin{aligned} I &= 1 - \sum_{j=1}^k f_j^2 \\ &= 1 - 1 \\ &= 0 \end{aligned} \quad (22)$$

Eterogeneità Massima: In questo caso supponiamo $\blacksquare\blacksquare\blacklozenge\blacktriangle\blacktriangle$, abbiamo $k = 3$ simboli diversi dunque la frequenza relativa sarà $\frac{\alpha}{k \cdot \alpha} = \frac{1}{k}$ e quindi

$$\begin{aligned} I &= 1 - \sum_{j=1}^k \frac{1}{k}^2 \\ &= 1 - k \frac{1}{k}^2 \\ &= 1 - \frac{1}{k} \\ &= \frac{k-1}{k} \end{aligned} \tag{23}$$

2.4.3 Indice di Gini normalizzato

Torna utile normalizzare l'indice di Gini quindi, dato $0 \leq I < 1$, possiamo considerare

$$I' = \frac{k}{k-1} I \tag{24}$$

2.4.4 Entropia

Denotiamo l'entropia con

$$H = \sum_{j=1}^k f_j \cdot \log \frac{1}{f_j} \geq 0 \tag{25}$$

In caso di eterogeneità minima, ossia con $f_j = 1$ abbiamo $\frac{1}{f_j} = 1$ e dunque $H = 1 \cdot \log 1 = 0$. In caso invece di eterogeneità massima si ha $\forall j \ f_j = \frac{1}{k} \implies H = \sum_{j=1}^k \frac{1}{k} \cdot \log k = \log k$ e dunque $0 \leq H \leq \log k$. Da qui si può normalizzare in

$$H' = \frac{H}{\log k} \tag{26}$$

così da avere $0 \leq H' \leq 1$, utile con il logaritmo in base 2 per misurare in bit.

Indici di concentrazione

2.5

Immaginiamo di avere n osservazioni $a_1, \dots, a_n$ ordinate dalla più piccola alla più grande, ognuna delle quali rappresenta la quantità (o ricchezza) di un elemento del campione. Definiamo quindi la media campionaria e la somma totale come segue:

$$\bar{a} = \frac{1}{n} \sum_{i=1}^n a_i \tag{27}$$

$$\text{TOT} = n\bar{a} = \sum_{i=1}^n a_i \tag{28}$$

Possiamo considerare due situazioni estreme:

- (1) **Caso di concentrazione minima:** tutti gli elementi del campione assumono lo stesso valore $a_1 = a_2 = \dots = a_n$
- (2) **Caso di concentrazione massima:** tutti gli elementi del campione assumono valore 0, tranne uno che vale $n\bar{a}$

Definiamo ora due frequenze relative cumulate:

- **Frequenza relativa cumulata degli individui fino alla i -esima osservazione:**

$$F_i = \frac{i}{n} \quad \forall i = 1, \dots, n \tag{29}$$

- **Quantità relativa cumulata fino alla i -esima osservazione:**

$$Q_i = \frac{\sum_{k=1}^i a_k}{\text{TOT}} \quad (30)$$

Definiamo anche alcune proprietà:

- $0 \leq F_i \leq 1$ e $0 \leq Q_i \leq 1$
- $Q_i \leq F_i$ poiché le osservazioni sono ordinate in maniera crescente
- $Q_i = F_i$ nel caso di concentrazione minima
- $Q_n = F_n$

Pertanto, per $i = 1, \dots, n$, le coppie (F_i, Q_i) indicano che il $100F_i\%$ della popolazione detiene il $100Q_i\%$ della quantità considerata.

2.5.1 Indice di Gini per la concentrazione

L'indice di Gini è definito come:

$$G = \frac{\sum_{i=1}^{n-1} (F_i - Q_i)}{\sum_{i=1}^{n-1} F_i} \quad (31)$$

Questo indice fornisce una misura della disuguaglianza nella distribuzione della quantità considerata. Maggiore è il valore di G , maggiore è la disuguaglianza. Con l'indice di Gini è possibile generare una curva di punti nota come *curva di Lorenz*. L'area tra la curva di Lorenz e la bisettrice di equidistribuzione rappresenta il valore dell'indice di Gini. Un indice di Gini pari a zero indica una distribuzione perfettamente equa, mentre un indice di Gini pari a uno indica una massima disuguaglianza.

Trasformazioni lineari

2.6

Nel caso serva effettuare una trasformazione lineare per mappare dei valori $\{v_1 \dots v_n\}$ da un intervallo $[a, b]$ a un altro $[c, d]$, partendo da

$$\frac{x' - c}{d - c} = \frac{x - a}{b - a} \quad (32)$$

posso definire una funzione $f : X \mapsto X'$ tale che

$$v' = f(v) = c + \frac{d - c}{b - a} \cdot (v - a) \quad (33)$$

2.6.1 Traslazione

Dato $k > 0$

$$\begin{aligned} v &\mapsto v' = v + k \\ v &\mapsto v' = v - k \end{aligned} \quad (34)$$

La traslazione non ha effetto sulle frequenze. Media, mediana e quantili vengono traslati. I range tra dati e i range interquartili restano invariati e non ha nessun effetto sulla varianza (e quindi sulla deviazione standard).

2.6.2 Contrazione e dilatazione

Dato $h \in \mathbb{R}$

$$\begin{aligned} h &> 1 \text{ contrazione} \\ h &< 1 \text{ dilatazione} \end{aligned} \quad (35)$$

Media, mediana e quantili vengono scalati. Range e distanza interquartile vengono scalati. La varianza viene invece scalata di $\frac{1}{h^2}$.

2.6.3 Standardizzazione

Viene impiegata per permettere di utilizzare una scala comune tra due variabili aleatorie.

$$g(v) = \frac{v - \bar{x}}{s_x} \quad (36)$$

2.6.4 Trasformazione logaritmica

La trasformazione logaritmica è un utile strumento quando si hanno dati che presentano variazioni significative. Immagina di avere due case: una costa 100.000€ e l'altra 1.000.000€. La differenza percentuale tra questi due prezzi è del 900%, ma può risultare più intuitiva se applichiamo la trasformazione logaritmica. Dopo la trasformazione, la differenza tra i due prezzi è circa 2.3.

$$v \mapsto v' = \log v \quad (37)$$

ANOVA

2.7

Utilizziamo le tecniche dell'*ANalysis Of VAriance* per confrontare due o più gruppi tramite la loro variabilità interna. Con x_i^g definiremo l'i-esima osservazione nel g-esimo gruppo.

$$\begin{aligned} \bar{x}^g &= \frac{1}{n^g} \sum_{i=1}^{n^g} x_i^g \\ \implies n^g \bar{x}^g &= \sum_{i=1}^{n^g} x_i^g \\ \implies \sum_{g=1}^G n^g \bar{x}^g &= \sum_{g=1}^G \sum_{i=1}^{n^g} x_i^g \\ \implies \frac{1}{n} \sum_{g=1}^G n^g \bar{x}^g &= \frac{1}{n} \cdot \text{somma delle osservazioni} \\ \implies \frac{1}{n} \sum_{g=1}^G n^g \bar{x}^g &= \bar{x} \end{aligned} \quad (38)$$

Da qui possiamo quindi dichiarare SS_T (*Sum of Squares Total*), SS_W (*Sum of Squares Within*) e SS_B (*Sum of Squares Between*).

$$\begin{aligned} SS_T &= \sum_{g=1}^G \sum_{i=1}^{n^g} (x_i^g - \bar{x})^2 \\ SS_W &= \sum_{g=1}^G \sum_{i=1}^{n^g} (x_i^g - \bar{x}^g)^2 \\ SS_B &= \sum_{g=1}^G (\bar{x}^g - \bar{x})^2 \end{aligned} \quad (39)$$

Possiamo quindi ottenere:

Varianza: $s^2 = \frac{SS_T}{n-1}$

Varianza Entro i Gruppi: $s^2 = \frac{SS_W}{n-G}$

Varianza Tra i Gruppi: $s^2 = \frac{SS_B}{G-1}$

Inoltre $SS_T = SS_W + SS_B$ e $\frac{SS_T}{n-1} = \frac{n-G}{n-1} \frac{SS_W}{n-G} + \frac{G-1}{n-1} \frac{SS_B}{G-1}$. L'ANOVA viene spesso utilizzata per testare l'ipotesi che non ci siano differenze significative tra i gruppi. Questo viene fatto confrontando il rapporto delle varianze tra i gruppi (SS_B) e all'interno dei gruppi (SS_W). Se il rapporto è sufficientemente grande da suggerire che la variabilità tra i gruppi è significativa rispetto alla variabilità all'interno dei gruppi, possiamo respingere l'ipotesi e concludere che almeno uno dei gruppi è significativamente diverso dagli altri.