

Capitolo 6

Modelli Continui

Siccome ora si lavora su intervalli continui, non ha più senso parlare della funzione di massa, in quanto ogni valore preciso avrebbe probabilità pari a 0. Fissato un punto a e un ε piccolo a piacere, definisco dunque la funzioni di densità nel seguente modo

$$\begin{aligned} f_X(a) &= \int_{a-\frac{\varepsilon}{2}}^{a+\frac{\varepsilon}{2}} f_x(x) \, dx \\ &\approx \varepsilon f(a) \end{aligned} \quad (1)$$

E posso dire che

$$\int_{-\infty}^{+\infty} f_x(x) \, dx = 1 \quad (2)$$

Inoltre definisco la funzione di ripartizione come

$$F_X(x) = \int_{-\infty}^x f_x(u) \, du \quad (3)$$

Da cui si evince che la funzione di ripartizione non è altro che la primitiva della funzione di densità.

Modello Uniforme Continuo

6.1

$$X \sim U([a, b]) \quad (4)$$

- **Supporto:** $D_X = [a, b] \subseteq \mathbb{R}$
- **Funzione di densità:**

$$f_X(x) = \frac{1}{b-a} \mathbb{I}_{[a,b]}(x) \quad (5)$$

- **Funzione di ripartizione:**



$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= \int_{-\infty}^x f_X(u) \, du \\ &= \int_a^x \frac{1}{b-a} \, du \\ &= \frac{1}{b-a} u \Big|_a^x \\ &= \frac{x-a}{b-a} \mathbb{I}_{[a,b]}(x) + \mathbb{I}_{(b,\infty)}(x) \end{aligned} \quad (6)$$

• **Valore atteso:**

$$\begin{aligned}
 \mathbb{E}(X) &= \int_{-\infty}^{\infty} x f_X(x) dx \\
 &= \int_a^b \frac{x}{b-a} dx \\
 &= \frac{1}{b-a} \int_a^b x dx \\
 &= \frac{1}{b-a} \frac{x^2}{2} \Big|_a^b \\
 &= \frac{1}{b-a} \frac{b^2 - a^2}{2} \\
 &= \frac{1}{b-a} \frac{(b+a)(b-a)}{2} \\
 &= \frac{b+a}{2}
 \end{aligned} \tag{7}$$

• **Varianza:**

$$\begin{aligned}
 Var(X) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 \\
 &= \mathbb{E}(X^2) - \left(\frac{b+a}{2}\right)^2 \\
 &= \mathbb{E}(X^2) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\int_a^b x^2 f_X(x) dx\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\frac{1}{b-a} \int_a^b x^2 dx\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\frac{1}{b-a} \frac{x^3}{3} \Big|_a^b\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\frac{b^3 - a^3}{3(b-a)}\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\frac{(b-a)(a^2 + ab + b^2)}{3(b-a)}\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \left(\frac{a^2 + ab + b^2}{3}\right) - \left(\frac{b+a}{2}\right)^2 \\
 &= \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} \\
 &= \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} \\
 &= \frac{4a^2 + 4ab + 4b^2 - 3a^2 - 6ab - 3b^2}{12} \\
 &= \frac{a^2 - 2ab + b^2}{12} \\
 &= \frac{(b-a)^2}{12}
 \end{aligned} \tag{8}$$



6.1.1 Considerazione 1

$$\begin{aligned}
 P(X \in \mathbb{I}) &= \int f_X(x) \, dx \\
 &= \int_{\mathbb{I}} \frac{1}{b-a} \, dx \\
 &= \frac{1}{b-a} \int_{\mathbb{I}} dx \\
 &= \frac{1}{b-a} x \int_{\mathbb{I}} \\
 &= \frac{|\mathbb{I}|}{b-a}
 \end{aligned}
 \tag{9}$$

6.1.2 Considerazione 2

$$\begin{aligned}\int_{-\infty}^{\infty} f_X(x) dx &= \int_a^b \frac{1}{b-a} dx \\ &= \frac{1}{b-a} x \int_a^b \\ &= \frac{b-a}{b-a} \\ &= 1\end{aligned}\tag{10}$$

6.1.3 Esempio

Sappiamo che $X \sim U([0, 30])$ e X è il minuto, dalle 07:00 in poi, nel quale arrivo alla fermata dell'autobus: qual è la probabilità che io attenda meno di 5 minuti per l'autobus, sapendo che l'autobus passa una volta ogni 15 minuti (alle 07:00, 07:15 e 07:30)?

$$\begin{aligned}P(\text{attendo meno di 5 minuti}) &= P(X = 0 \cup 10 < X \leq 15 \cup 25 < X \leq 30) \\ &= P(X = 0) + P(10 < X \leq 15) + P(25 < X \leq 30) \\ &\rightarrow P(X = 0) = 0 \\ &= P(10 < X \leq 15) + P(25 < X \leq 30) \\ &\rightarrow P(\alpha < X \leq \beta) = F_X(\beta) - F_X(\alpha) \\ &= F_X(15) - F_X(10) + F_X(30) - F_X(25) \\ &= \frac{15-0}{30-0} - \frac{10-0}{30-0} + \frac{30-0}{30-0} - \frac{25-0}{30-0} \\ &= \frac{15-10}{30} + \frac{30-25}{30} \\ &= \frac{5}{30} + \frac{5}{30} \\ &= \frac{10}{30} \\ &= \frac{1}{3}\end{aligned}\tag{11}$$

Modello Esponenziale

6.2

La distribuzione esponenziale descrive la "durata di vita" di un fenomeno senza memoria. Per esempio può essere usata per calcolare l'occorrenza di eventi come terremoti o predizioni varie. Essa è rappresentata da:

$$X \sim E(\lambda) \quad \lambda \in \mathbb{R}^+ \setminus \{0\}\tag{12}$$

- **Supporto:** $D_x = \mathbb{R}^+$
- **Funzione di densità:**

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{I}_{[0, +\infty)}(x)\tag{13}$$

- Funzione di ripartizione:



$$\begin{aligned}
 F_X(x) &= \int_0^x f_X(y) \, dy \\
 &= \int_0^x \lambda e^{-\lambda y} \, dy \\
 &\rightarrow z = \lambda y, \quad dz = \lambda \, dy \\
 &= \int_0^{\lambda x} e^{-z} \, dz \\
 &= -e^{-z} \Big|_0^{\lambda x} \\
 &= -e^{-\lambda x} + e^0 \\
 &= (1 - e^{-\lambda x}) \mathbb{I}_{R^+}(x)
 \end{aligned} \tag{14}$$

- Valore atteso:

$$\begin{aligned}
 \mathbb{E}(X) &= \int_0^\infty x f_X(x) \, dx \\
 &= \int_0^\infty x \lambda e^{-\lambda x} \, dx \\
 &\rightarrow f(x) = x, \quad g'(x) = \lambda e^{-\lambda x}, \quad g(x) = -e^{-\lambda x} \\
 &= -x e^{-\lambda x} \Big|_0^\infty + \int_0^\infty e^{-\lambda x} \, dx \\
 &= 0 + \int_0^\infty e^{-\lambda x} \, dx \\
 &= \int_0^\infty e^{-\lambda x} \, dx \\
 &\rightarrow \text{introduco } \lambda \\
 &= \frac{1}{\lambda} \int_0^\infty \lambda e^{-\lambda x} \, dx \\
 &\rightarrow \text{guardo la Considerazione 1 qui sotto} \\
 &= \frac{1}{\lambda} \cdot 1 \\
 &= \frac{1}{\lambda}
 \end{aligned} \tag{15}$$

• **Varianza:**

$$\begin{aligned}
Var(X) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 \\
&= \mathbb{E}(X^2) - \left(\frac{1}{\lambda}\right)^2 \\
&= \mathbb{E}(X^2) - \frac{1}{\lambda^2} \\
&= \left(\int_0^\infty x^2 \lambda e^{-\lambda x} dx\right) - \frac{1}{\lambda^2} \\
&\rightarrow f(x) = x^2, \quad g'(x) = \lambda e^{-\lambda x}, \quad g(x) = -e^{-\lambda x} \\
&= \left(-x^2 e^{-\lambda x} \int_0^\infty + \int_0^\infty 2x e^{-\lambda x} dx\right) - \frac{1}{\lambda^2} \\
&= \left(0 + 2 \int_0^\infty x e^{-\lambda x} dx\right) - \frac{1}{\lambda^2} \\
&= \left(2 \int_0^\infty x e^{-\lambda x} dx\right) - \frac{1}{\lambda^2} \\
&\rightarrow \text{introduco } \lambda \\
&= \left(\frac{2}{\lambda} \int_0^\infty \lambda x e^{-\lambda x} dx\right) - \frac{1}{\lambda^2} \\
&\rightarrow f(x) = x, \quad g'(x) = \lambda e^{-\lambda x}, \quad g(x) = -e^{-\lambda x} \\
&= \left(\frac{2}{\lambda} \cdot \left(-x e^{-\lambda x} \int_0^\infty + \int_0^\infty e^{-\lambda x} dx\right)\right) - \frac{1}{\lambda^2} \\
&= \left(\frac{2}{\lambda} \cdot \left(0 + \int_0^\infty e^{-\lambda x} dx\right)\right) - \frac{1}{\lambda^2} \\
&= \left(\frac{2}{\lambda} \cdot \left(\int_0^\infty e^{-\lambda x} dx\right)\right) - \frac{1}{\lambda^2} \\
&\rightarrow \text{introduco } \lambda \\
&= \left(\frac{2}{\lambda} \cdot \left(\frac{1}{\lambda} \int_0^\infty \lambda e^{-\lambda x} dx\right)\right) - \frac{1}{\lambda^2} \\
&\rightarrow \text{guardo la Considerazione 1 qui sotto} \\
&= \left(\frac{2}{\lambda} \cdot \left(\frac{1}{\lambda} \cdot 1\right)\right) - \frac{1}{\lambda^2} \\
&= \left(\frac{2}{\lambda} \cdot \frac{1}{\lambda}\right) - \frac{1}{\lambda^2} \\
&= \frac{2}{\lambda^2} - \frac{1}{\lambda^2} \\
&= \frac{1}{\lambda^2} \\
\\
&\implies \sigma_X = \mathbb{E}(X)
\end{aligned} \tag{16}$$



6.2.1 Considerazione 1

$$\begin{aligned}
 \int_0^{\infty} f_X(x) dx &= \int_0^{\infty} \lambda e^{-\lambda x} dx \\
 &\rightarrow y = \lambda x, \quad dy = \lambda dx \\
 &= \int_0^{\infty} e^{-y} dy \\
 &= -e^{-y} \Big|_0^{\infty} \\
 &= 0 + e^{-0} \\
 &= 1
 \end{aligned} \tag{17}$$

6.2.2 Considerazione 2

Come il modello geometrico, così il modello esponenziale gode dell'assenza di memoria. Ipotizziamo infatti di avere giustamente

$$F_X(x) = 1 - e^{-\lambda x} \tag{18}$$

E dunque

$$\begin{aligned} P(X > x) &= 1 - F_X(x) \\ &= e^{-\lambda x} \end{aligned} \quad (19)$$

Quindi

$$\begin{aligned} P(X > s + t) &= e^{-\lambda(s+t)} \\ &= e^{-\lambda s} \cdot e^{-\lambda t} \end{aligned} \quad (20)$$

Infatti

$$\begin{aligned} P(X > s + t) &= P(X > s) \cdot P(X > t) \\ \rightarrow P(X > s) &= \frac{P(X > s + t)}{P(X > t)} \\ \implies P(X > s + t \mid X > t) &= P(X > s) \end{aligned} \quad (21)$$

6.2.3 Considerazione 3

Ora immagino $x_1, \dots, x_n$ indipendenti e $Y_i = \max_i X_i$, allora:

$$\begin{aligned} F_Y(x) &= P(Y \leq x) \\ &= P(\max_i X_i \leq x) \\ &\rightarrow \max_i X_i \leq x \iff \forall i X_i \leq x \\ &= P(\forall i X_i \leq x) \\ &\rightarrow \text{per indipendenza } P(X_1 \leq x, X_2 \leq x, \dots) \\ &= \prod_{i=1}^n P(X_i \leq x) \\ &= \prod_{i=1}^n F_{X_i}(x) \end{aligned} \quad (22)$$

Quindi se $X_1, \dots, X_n$ sono i.i.d. (*indipendenti e identicamente distribuite*) secondo F allora

$$\begin{aligned} F_Y(x) &= \prod_{i=1}^n F(x) \\ &= F(x)^n \end{aligned} \quad (23)$$

Per cui, date $X_1, \dots, X_n$ indipendenti (e non i.i.d), allora

$$\begin{aligned}
Z &= \min_{i=1, \dots, n} X_i \\
&= P(Z > x) \\
&\rightarrow \min_i X_i > x \iff \forall i X_i > x \\
&= P(\forall i X_i > x) \\
&= \prod_{i=1}^n P(X_i > x) \\
&= \prod_{i=1}^n (1 - P(X_i \leq x)) \\
&= \prod_{i=1}^n (1 - F_{X_i}(x)) \\
&\rightarrow \text{possiamo vedere } P(Z > x) \text{ come } 1 - P(Z \leq x) \\
&= 1 - \prod_{i=1}^n (1 - F_{X_i}(x)) \\
&\rightarrow X_i \text{ i.i.d secondo } F_Z(x) = 1 - (1 - F_Z(x))^n \\
&\rightarrow X_i \sim E(\lambda_i) \text{ e indipendente} \\
&\rightarrow F_{X_i}(x) = 1 - e^{-\lambda_i x} \\
&= 1 - \prod_{i=1}^n (e^{-\lambda_i x}) \\
&= 1 - e^{\sum_{i=1}^n -\lambda_i x} \\
&= 1 - e^{-x \sum_{i=1}^n \lambda_i} \\
&= 1 - e^{-x \lambda} \\
&= 1 - e^{-\lambda x} \\
&\implies F_Z = 1 - e^{-\lambda x} \\
&\implies Z \sim E(\lambda)
\end{aligned} \tag{24}$$

Ho dimostrato che se considero $X_1, \dots, X_n$ e $\forall i X_i \sim E(\lambda_i)$ allora $\min X_i \sim E(\sum_{i=1}^n \lambda_i)$

6.2.4 Considerazione 4

Dato $X \sim E(\lambda)$ con $c \in R^+$ e $Y = c \cdot X$, allora:

$$\begin{aligned}
F_Y(x) &= P(Y \leq x) \\
&= P(cX \leq x) \\
&= P\left(X \leq \frac{x}{c}\right) \\
&= F_X\left(\frac{x}{c}\right) \\
&= 1 - e^{-\lambda \frac{x}{c}} \\
&= 1 - e^{-\frac{\lambda}{c} x}
\end{aligned} \tag{25}$$

6.2.5 Esempio 1

La mia $X \sim E(1)$ rappresenta le ore necessarie per riparare un macchinario, qual è la probabilità che io ci impieghi più di 2 ore per ripararlo?:

$$\begin{aligned} P(X > 2) &= 1 - F_X(2) \\ &= 1 - (1 - e^{-2}) \\ &= e^{-2} \\ &\approx 0.1353 \end{aligned} \tag{26}$$

Qual è invece la probabilità che io ci impieghi 3 ore dato che prima ce ne ho messe 2 di ore?

$$\begin{aligned} P(X > 3 \mid X > 2) &= P(X > 1 + 2 \mid X > 2) \\ &= P(X > 1) \\ &= e^{-1} \\ &\approx 0.3678 \end{aligned} \tag{27}$$

6.2.6 Esempio 2

La mia $X \sim E\left(\frac{1}{20}\right)$ rappresenta le migliaia di km che l'auto percorre prima di rompersi. Ho usato l'auto per 10k km, la vendo e il compratore si domanda la probabilità che duri altri 20km, quindi:

$$\begin{aligned} P(X > 30 \mid X > 10) &= P(X > 20 + 10 \mid X > 10) \\ &= P(X > 20) \\ &= e^{-\frac{20}{20}} \\ &= e^{-1} \\ &\approx 0.3678 \end{aligned} \tag{28}$$

Come cambierebbe la risposta se $X \sim U((0, 40))$?

$$\begin{aligned} P(X > 30 \mid X > 10) &= \frac{P(X > 30 \cap X > 10)}{P(X > 10)} \\ &\rightarrow \text{se si verifica } X > 30 \text{ allora si è verificato anche } X > 10 \\ &= \frac{P(X > 30)}{P(X > 10)} \\ &= \frac{P(30 < X < 40)}{P(10 < X < 40)} \\ &= \frac{F_X(40) - F_X(30)}{F_X(40) - F_X(10)} \\ &= \frac{\frac{40-0}{40-0} - \frac{30-0}{40-0}}{\frac{40-0}{40-0} - \frac{10-0}{40-0}} \\ &= \frac{\frac{10}{40}}{\frac{30}{40}} \\ &= \frac{1}{3} \end{aligned} \tag{29}$$

$$X \sim G(\mu, \sigma) \quad \mu \in \mathbb{R}, \sigma \in \mathbb{R}^+ \setminus \{0\} \tag{30}$$

Questo modello è noto anche come *Modello Normale*, tuttavia a volte specifica un caso particolare del Modello Gaussiano.

- **Supporto:** $D_x = \mathbb{R}$

- **Funzione di densità:**

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (31)$$

- **Funzione di ripartizione:**



$$F_X(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} du \quad (32)$$

- **Valore atteso:**

$$E(X) = \mu \quad (33)$$

- **Varianza:**

$$Var(X) = \sigma^2 \quad (34)$$



6.3.1 Considerazione 1

Consideriamo

$$\lim_{x \rightarrow \infty} f_X(x) = \lim_{x \rightarrow \infty} \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (35)$$

Per prima cosa calcoliamo la derivata prima $f'_X(x)$:

$$\begin{aligned} f'_X(x) &= -\frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \frac{1}{2\sigma^2} 2(x-\mu) \\ &= -\frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \frac{1}{\sigma^2} (x-\mu) \\ &= -\frac{1}{\sqrt{2\pi}\sigma^3} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot (x-\mu) \\ &= \frac{1}{\sqrt{2\pi}\sigma^3} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot (\mu-x) \\ &\rightarrow f'_X(x) \geq 0 \text{ quando } \mu-x \geq 0 \rightarrow x \leq \mu \end{aligned} \quad (36)$$

$\Rightarrow$ cresce verso μ per poi decrescere

Ora calcoliamo la derivata seconda $f''_X(x)$:

$$\begin{aligned} f''_X(x) &= \frac{1}{\sqrt{2\pi}\sigma^3} \cdot \left(e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \left(-\frac{2(x-\mu)}{2\sigma^2} \right) \cdot (\mu-x) - e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right) \\ &\quad \frac{1}{\sqrt{2\pi}\sigma^3} \cdot \left(e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \left(-\frac{(x-\mu)}{\sigma^2} \right) \cdot (\mu-x) - e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right) \\ &\quad \frac{1}{\sqrt{2\pi}\sigma^3} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \left(\frac{(x-\mu)^2}{\sigma^2} - 1 \right) \\ &\rightarrow f''_X(x) \geq 0 \text{ quando } \frac{(x-\mu)^2}{\sigma^2} - 1 \geq 0 \rightarrow \left(\frac{x-\mu}{\sigma} \right)^2 \geq 1 \end{aligned} \quad (37)$$

Questi calcoli dimostrano che non solo $G(\mu, \sigma)$ è convessa fino a $\mu - \sigma$ e da $\mu + \sigma$, con μ al centro, ma anche che quindi essa assumerà la classica forma a campana. Inoltre se abbiamo $\mu_2 < \mu_1$, allora μ_2 farà traslare la funzione a sinistra rispetto a μ_1 , siccome stiamo spostando a sinistra il valore atteso; mentre se $\sigma_2 < \sigma_1$ allora avremo un picco, sempre in μ ma più evidenziato per σ_2 , in quando stiamo dicendo che i dati sono meno devianti rispetto a σ_1 e quindi più concentrati.

6.3.2 Considerazione 2

$$\begin{aligned} f_X(\mu) &= \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(\mu-\mu)^2}{2\sigma^2}} \\ &= \frac{1}{\sqrt{2\pi}\sigma} \end{aligned} \quad (38)$$

Quindi la densità in μ sarà più grande tanto più σ è piccola.

6.3.3 Considerazione 3

Ipotizzo di essere abbastanza confidente del fatto che

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\left(\frac{x-\mu}{\sigma}\right)^2} dx = 1 \quad (39)$$

Ma come lo provo?

Innanzitutto considero $z = \frac{x-\mu}{\sigma}$ e quindi $dz = \frac{dx}{\sigma}$, dunque

$$\begin{aligned}
 I &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-z^2} dz \\
 &\rightarrow I \cdot I \\
 &= \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-x^2} dx \int_{-\infty}^{\infty} e^{-y^2} dy \\
 &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-x^2} e^{-y^2} dx dy \\
 &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(x^2+y^2)} dx dy \\
 &\rightarrow p \sin \theta = y, \quad p \cos \theta = x \text{ e matrice jacobiana} \\
 &= 1
 \end{aligned} \tag{40}$$

6.3.4 Considerazione 4

Partendo da $F_X(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} du$ io so che $\mu = \mathbb{E}(X)$ e che $\sigma^2 = Var(X)$, dunque se io prendo $y = ax + b$, se $X \sim G(\mu, \sigma)$ allora $Y \sim G(a\mu + b, a\sigma)$.

Inoltre so che se ho $X_1 \sim G(\mu_1, \sigma_1)$ e $X \sim G(\mu_2, \sigma_2)$ più indipendenza, allora avrò

$$X_1 + X_2 \sim G\left(\mu_1 + \mu_2, \sqrt{\sigma_1^2 + \sigma_2^2}\right) \tag{41}$$

N.B. Sto sommando variabili aleatorie, non funzioni. Nel caso della somma di funzioni non posso fare come ho scritto e il risultato anzi sarà una funzione multimodale.

6.3.5 Considerazione 5

Se usassi $Y = \frac{X-\mu}{\sigma}$ otterrei

$$\begin{aligned}
 \mathbb{E}(Y) &= \mathbb{E}\left(\frac{X-\mu}{\sigma}\right) \\
 &= \frac{1}{\sigma} \mathbb{E}(X - \mu) \\
 &= \frac{1}{\sigma} (\mathbb{E}(X) - \mu) \\
 &= \frac{1}{\sigma} (\mathbb{E}(X) - \mathbb{E}(X)) \\
 &= 0
 \end{aligned} \tag{42}$$

Inoltre:

$$\begin{aligned}
 Var(Y) &= Var\left(\frac{X-\mu}{\sigma}\right) \\
 &= \frac{1}{\sigma^2} Var(X - \mu) \\
 &= \frac{1}{\sigma^2} Var(X) \\
 &= 1
 \end{aligned} \tag{43}$$

Dunque otteniamo

$$X \sim G(\mu, \sigma) \rightarrow Y \sim G(0, 1) \tag{44}$$

Dunque $Y = \frac{X-\mu}{\sigma}$ non è altro che la gaussiana normale standard. Essa mi è utile perché tramite tabulati posso convertire i miei dati per usarli nella gaussiana standard.

6.3.6 Legge empirica

Se un campione numerico è approssimativamente normale, ha media campionaria $\bar{x}$ e deviazione standard s , allora:

- (1) Circa il 68% dei suoi dati cade nell'intervallo $\bar{x} \pm s$
- (2) Circa il 95% dei suoi dati cade nell'intervallo $\bar{x} \pm 2s$
- (3) Circa il 99.7% dei suoi dati cade nell'intervallo $\bar{x} \pm 3s$

6.3.7 Considerazione 6

Partendo dalla Considerazione 4, se invece di applicare una trasformazione lineare io avessi usato variabili aleatorie gaussiane, il risultato sarebbe stata una variabile aleatoria gaussiana, pertanto, avendo $X_1, \dots, X_n$ indipendenti, $\forall i \ X_i \sim G(\mu_i, \sigma_i)$ allora $Y = \sum_{i=1}^n X_i$. In particolare $\mathbb{E}(Y) = \sum_{i=1}^n \mu_i$, $Var(Y) = \sum_{i=1}^n \sigma_i^2$ e nel complesso

$$Y \sim G\left(\sum_{i=1}^n \mu_i, \sqrt{\sum_{i=1}^n \sigma_i^2}\right) \quad (45)$$

Quindi sommando variabili aleatorie che hanno un modello comune, ottengo una variabile aleatoria che fa ancora parte di quel modello comune, questo concetto è noto come **riproducibilità**. Quindi se X è una variabile casuale con media μ e deviazione standard σ , allora la standardizzazione di X tramite la trasformazione $Z = \frac{X-\mu}{\sigma} \sim G(0, 1)$ segue una distribuzione normale standard $N(0, 1)$. In altre parole, la variabile standardizzata Z ha media 0 e deviazione standard 1, indipendentemente dalla distribuzione originale di X . Questo processo rende le misurazioni comparabili, poiché esprime ciascun valore in termini di deviazioni standard dal valore atteso, facilitando così la valutazione delle relazioni e delle differenze tra dati che potrebbero avere scale diverse.

E' importante notare che la riproducibilità vale, oltre che per le variabili aleatorie gaussiane, anche per le variabili aleatorie poissoniane e per le binomiali, in condizioni specifiche, tant'è che

$$X_1 \sim B(n, p) \quad X_2 \sim B(m, p) \quad X_1 + X_2 \sim B(n + m, p) \quad (46)$$

$$X_1 \sim P(\lambda_1) \quad X_2 \sim P(\lambda_2) \quad X_1 + X_2 \sim P(\lambda_1 + \lambda_2) \quad (47)$$

A proposito della legge di riproducibilità, è giusto tenere in considerazione che la differenza di variabili aleatorie distribuite secondo un modello normale è anch'essa una variabile aleatoria normale. Infine, la distribuzione gaussiana e la distribuzione esponenziale, godono entrambe del concetto di scalabilità.

6.3.8 Considerazione 7

Cosa succede se voglio calcolare $F_X(x)$? Viene un integrale non risolvibile in forma analitica, quindi uso la Normale Standard:

$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) \\ &= P\left(Z \leq \frac{x - \mu}{\sigma}\right) \\ &= F_Z\left(\frac{x - \mu}{\sigma}\right) \\ &= \Phi \end{aligned} \quad (48)$$

E nel dettaglio valgono le seguenti proprietà:

- $\Phi(0) = \frac{1}{2}$
- $\Phi(-x) = P(Z > x) = 1 - P(Z \leq x) = 1 - \Phi(x)$

- $P(|X - \mu| \leq n\sigma) \implies P(-n \leq X \leq n) = P(|X| \leq n)$

In generale:

$$\begin{aligned}
 P(-n \leq Z \leq n) &= P(|Z| \leq n) \\
 &= \Phi(n) - \Phi(-n) \\
 &= \Phi(n) - (1 - \Phi(n)) \\
 &= 2\Phi(n) - 1
 \end{aligned} \tag{49}$$

6.3.9 Quantili

La mediana di X è $m \in \mathbb{R}$ tale che $P(X \leq m) = P(X \geq m) = \frac{1}{2}$ (ossia 0, il valore atteso).


La moda di X è la specificazione che massimizza la densità o la massa di probabilità (ossia 0, il valore atteso).

Il quantile di livello $q \in [0, 1]$ di X è la specificazione $x_q \in \mathbb{R}$ tale che $P(X \leq x) = q$. Dunque pongo $X \sim G(\mu, \sigma)$, da qui, se volessi calcolare $q = P(X \leq 2)$ procedo come


$$\begin{aligned}
 q &= P(X \leq x_q) \\
 &= F_X(x_q) \\
 &= F_X^{-1}(q)
 \end{aligned} \tag{50}$$

Da qui

- $F_X(F_X^{-1}(q))$
- $F_X^{-1}(q) = x_q$ (Funzione `ppf` di Python)
- $F_X(x_q) = q$



Risulta importante notare che il quantile Q1 e il quantile Q3 si trovano rispettivamente a $\mu - z \cdot \sigma$ e $\mu + z \cdot \sigma$, con $z = 0.675$. Questo perché osservando le tabelle della distribuzione cumulativa normale standardizzata, possiamo notare che $\Phi(-0.675) = 0.25 = 25\%$ e $\Phi(0.675) = 0.75 = 75\%$.



Per disegnare un Q-Q plot, ossia i grafici sovrastanti, basta seguire i seguenti passi:

- (1) Raccolgo i dati e mi assicuro di avere un numero abbastanza elevato di valori così da ottenere un'analisi significativa
- (2) Ordino i dati in ordine crescente
- (3) Calcolo i quantili teorici, solitamente di una distribuzione normale standard, e i quantili campionari
- (4) Creo una coppia di coordinate (x_i, y_i) dove le x_i saranno i quantili teorici mentre le y_i quelli campionari
- (5) Traccio la linea bisettrice di riferimento per osservare se i punti giacciono su essa

Esempio

Si determini il più piccolo valore di X , chiamiamolo $x_{0.8}$, tale che $P(X \leq x_{0.8}) \geq 0.8$. Questo non è altro che $F_X(x) \geq 0.8$ ossia il quantile 0.8 di X , che può essere facilmente calcolato con `X.ppf(0.8)`

6.3.10 Teorema Centrale del Limite

Il Teorema Centrale del Limite o Teorema del Limite Centrale asserisce che, dati $X_1, \dots, X_n$ i.i.d. allora $\forall i \mathbb{E}(X_i) = \mu$, $Var(X_i) = \sigma^2$ si ha che

$$\sum_{i=1}^n X_i \sim N(n\mu, \sqrt{n}\sigma) \quad (51)$$

E quindi, posto

$$Y_n = \frac{\frac{1}{n} \sum_{j=1}^n X_j - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1) \quad (52)$$

Allora

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1) \quad (53)$$

E dunque

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x) \quad (54)$$

Dove tanto più è grande n , tanto migliore sarà l'approssimazione.

Empiricamente si evidenzia come per $n \geq 30$ si iniziano ad avere risultati accettabili. In ogni caso se voglio verificare qualitativamente la bontà dell'approssimazione posso usare un QQ-plot.

Il TCL è valido per ognuna delle distribuzioni viste in questo corso e ricordiamoci infine che quindi, nel caso della media campionaria, avremo

$$\frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \quad (55)$$

6.3.11 Teorema di De Moivre-Laplace

Una distribuzione normale può essere usata per approssimare una distribuzione binomiale, a patto di avere un parametro n sufficientemente grande. Dato $X \sim B(n, p)$ con n grande, allora

$$X = \sum_{i=1}^n X_i \sim N\left(np, \sqrt{np(1-p)}\right) \rightarrow \frac{X - np}{\sqrt{np(1-p)}} \sim N(0, 1) \quad (56)$$

In generale

$$\frac{X - \mu}{\sqrt{Var(X)}} \sim N(0, 1) \quad (57)$$

N.B. Su Python andranno usati i comandi `Z = st.norm()` per definire una distribuzione normale e `Z.rvs()` per ricevere una specificazione plausibile per una variabile aleatoria della distribuzione normale create precedentemente. Entrambe le funzioni appartengono al modulo `scipy.stats`.

6.3.12 Esempio 1

Per $n > 1$ si controlli che $P(-\varepsilon < T_n - p < \varepsilon) \approx 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1$:

$$\begin{aligned} P(-\varepsilon < T_n - p < \varepsilon) &\approx P\left(-\frac{\varepsilon\sqrt{n}}{\sigma} < Z < \frac{\varepsilon\sqrt{n}}{\sigma}\right) \\ &\approx 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1 \end{aligned} \quad (58)$$

6.3.13 Esempio 2

Verifico che $P(\mu - k \leq X \leq \mu + k) \leq 2\Phi\left(\frac{k}{\sigma}\right) - 1$:

$$\begin{aligned}
 P(\mu - k \leq X \leq \mu + k) &= P(\mu \leq X - k \leq \mu) \\
 &= P(\mu \leq X^* \leq \mu) \\
 &= F_X\left(\frac{k}{\sigma}\right) - F_X\left(-\frac{k}{\sigma}\right) \\
 &\approx \Phi\left(\frac{k}{\sigma}\right) - \Phi\left(-\frac{k}{\sigma}\right) \\
 &= \Phi\left(\frac{k}{\sigma}\right) - \left(1 - \Phi\left(\frac{k}{\sigma}\right)\right) \\
 &= 2\Phi\left(\frac{k}{\sigma}\right) - 1
 \end{aligned} \tag{59}$$

6.3.14 Esempio 3

Ipotizzo di avere 25000 polizze auto e X è il risarcimento annuo di un cliente. Mi aspetto di risarcire intorno ai 320 euro ogni cliente, quindi $\mathbb{E}(X) = 320$ euro, con una deviazione di $\sigma_x = 540$ euro: qual è la probabilità di dover risarcire più di $8.3 \cdot 10^6$ euro?

$$\begin{aligned}
 P(\text{più di } 8.3 \cdot 10^6 \text{ di risarcimento/anno}) &= P(Y > 8.3 \cdot 10^6) \\
 &\rightarrow \text{per il TCL } \sum_{i=1}^n X_i \sim N(n\mu, \sqrt{n}\sigma) \\
 &\rightarrow \sum_{i=1}^{25000} X_i = Y \sim N\left(25000 \cdot 320, \sqrt{25000} \cdot 540\right) \\
 &= Y \sim N(8 \cdot 10^6, 8.54 \cdot 10^6) \\
 &\rightarrow \text{standardizzo} \\
 &= P\left(\frac{Y - 8 \cdot 10^6}{8.54 \cdot 10^6} > \frac{8.3 \cdot 10^6 - 8 \cdot 10^6}{8.54 \cdot 10^6}\right) \\
 &= P((\sim N(0, 1)) > (\approx 3.51)) \\
 &\approx P(Z > 3.51) \\
 &= 1 - \Phi(3.51) \\
 &\approx 2.2 \cdot 10^{-4}
 \end{aligned} \tag{60}$$

Tuttavia sto approssimando due volte, qual è la soglia entro cui questa approssimazione continua a valere? Lo domando alla *Funzione Cumulativa Empirica (ECDF)*

$$\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{(-\infty, x]}(X_i) \tag{61}$$

E quindi

$$\hat{F}(8.3 \cdot 10^6) = \frac{1}{25000} \sum_{i=1}^n \mathbb{I}_{(-\infty, 8.3 \cdot 10^6]}(X_i) \tag{62}$$

Ipotizzo (con dati immaginari) che $\hat{F}(8.3 \cdot 10^6) \approx 0.85$, questo significa che l'85% delle osservazioni è inferiore o uguale a $8.3 \cdot 10^6$ e che quindi l'approssimazione normale sembra funzionare abbastanza bene fino a quel punto di divergenza. Quindi se per esempio avessi avuto bisogno di una precisione del 95% quel valore non sarebbe andato bene.

6.3.15 Esempio 4

Il 30% degli iscritti è frequentante, quindi $P(\text{uno studente sia frequentante}) = 0.3$. Modelliamo X come il numero di studenti frequentanti su 450, tale che $X \sim B(450, 0.3)$. La nostra aula ha 150 posti: qual è la probabilità di superare la capienza massima dell'aula?

Sappiamo che

$$X \rightsquigarrow N\left(450 \cdot 0.3, \sqrt{450 \cdot 0.3 \cdot 0.7}\right) \rightarrow X \rightsquigarrow N(135, 9.72) \quad (63)$$

Quindi servendoci della distribuzione normale standard $Z \sim N(0, 1)$

$$\begin{aligned} P(X > 150) &= P\left(\frac{X - 135}{9.72} > \frac{150 - 135}{9.72}\right) \\ &\approx P(Z > 1.59) \\ &\approx 0.06 \end{aligned} \quad (64)$$

Dunque ho un 6% di giornate di lezione in cui gli studenti iscritti non trovano posto in aula.

6.3.16 Esempio 5

La media delle precipitazioni del 2022 è 12.08cm mentre la deviazione standard è 9.1cm. Le precipitazioni del 2022 sommate a quelle del 2023, supereranno i 25cm?

Sappiamo che $X_{2022}, X_{2023} \sim N(\mu, \sigma)$, dunque

$$Y = X_{2022} + X_{2023} \sim N\left(2\mu, \sqrt{2}\sigma\right) \quad (65)$$

Allora

$$\begin{aligned} P(X_{2022} + X_{2023} > 25) &= P(Y > 25) \\ &= P\left(\frac{Y - 2 \cdot 12.08}{\sqrt{2} \cdot 3.1} > \frac{25 - 2 \cdot 12.08}{\sqrt{2} \cdot 3.1}\right) \\ &= P(Z > 0.1916) \\ &\approx 0.4240 \end{aligned} \quad (66)$$

Cosa succede se volessi calcolare la probabilità che nel 2022 ci sia stata più pioggia (di almeno 3cm)?

$$P(X_{2022} > X_{2023} + 3) = P(X_{2022} - X_{2023} > 3)$$

Quindi se io definisco $T = X_{2022} - X_{2023}$, il cui risultato sarà una distribuzione normale standard, grazie alla proprietà della riproducibilità, allora

$$\begin{aligned} \mathbb{E}(T) &= \mathbb{E}(X_{2022}) - \mathbb{E}(X_{2023}) \\ &= 0 \end{aligned} \quad (67)$$

E infine

$$\begin{aligned} \text{Var}(T) &= \text{Var}(X_{2022} - X_{2023}) \\ &= \text{Var}(X_{2022}) + \text{Var}(X_{2023}) \\ &= 2\sigma^2 \end{aligned} \quad (68)$$

6.3.17 Esempio 6

So che $P(|\bar{X}_n - \mu| \leq \varepsilon)$, determino n dato α tale che $P(|\bar{X}_n - \mu| \leq \varepsilon) \geq \alpha$. Risolvo il seguente

$$\begin{aligned}
 P(|\bar{X}_n - \mu| \leq \varepsilon) &= P(-\varepsilon \leq \bar{X}_n - \mu \leq \varepsilon) \\
 &\rightarrow TCL \\
 &= P\left(-\frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}} \leq \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \leq \frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}}\right) \\
 &\approx P\left(-\frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}} \leq Z \leq \frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}}\right) \\
 &= \Phi\left(\frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}}\right) - \Phi\left(-\frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}}\right) \\
 &= 2\Phi\left(\frac{\varepsilon}{\frac{\sigma}{\sqrt{n}}}\right) - 1 \\
 &= 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1 \\
 &\rightarrow 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1 \geq \alpha \\
 &\rightarrow \Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) \geq \frac{\alpha + 1}{2} \\
 &\rightarrow \frac{\varepsilon\sqrt{n}}{\sigma} \geq \Phi^{-1}\left(\frac{\alpha + 1}{2}\right) \\
 &\rightarrow \sqrt{n} \geq \Phi^{-1}\left(\frac{\alpha + 1}{2}\right) \cdot \frac{\sigma}{\varepsilon} \\
 &\rightarrow n \geq \left(\Phi^{-1}\left(\frac{\alpha + 1}{2}\right) \cdot \frac{\sigma}{\varepsilon}\right)^2
 \end{aligned} \tag{69}$$

Esercizi

6.4

Uno stabilimento ha 6 macchinari che usano in media energia elettrica per 20 minuti ogni ora.

- Se i macchinari vengono usati indipendentemente, mostrare che la probabilità che 4 o più macchinari usino energia elettrica contemporaneamente è 0.1.

Consideriamo la variabile casuale X = "numero di macchine che consumano energia", possiamo quindi assumere che $X \approx B(n, p)$, dove $n = 6$, numero totale di macchinari disponibili e $p = \frac{20}{60} = \frac{1}{3} = 0.33$, "successo" ossia minuti in cui i macchinari usano energia ogni ora. Dunque $X \approx B(6, 0.33)$. A questo punto basterà considerare il seguente

$$\begin{aligned}
 P(X \geq 4) &= P(X = 4) + P(X = 5) + P(X = 6) \\
 &= 0.0823 + 0.0165 + 0.0014 \\
 &= 0.1002
 \end{aligned} \tag{70}$$

Ovviamente potevo anche considerare

$$P(X \geq 4) = 1 - P(X = 3) - P(X = 2) - P(X = 1) - P(X = 0) = \dots$$

- Se lo stabilimento avesse 60 macchinari, quale sarebbe la probabilità di avere al massimo 30 macchinari in funzione contemporaneamente?

Come prima $X \approx B(60, 0.33)$, ma siccome abbiamo un valore di n elevato, possiamo ricorrere all'approssimazione normale della distribuzione binomiale considerando

$$N\left(np, \sqrt{np(1-p)}\right)$$

Il nostro μ non sarà altro che $np = 60 \cdot \frac{1}{3} = 20$ mentre la varianza $np(1-p) = 20 \cdot \frac{2}{3} = 13.33$ e quindi la deviazione standard sarà uguale a $\sqrt{13.33} = 3.65$. A questo punto la probabilità di avere al massimo 30 macchinari in funzione risulta essere

$$\begin{aligned} P(X \leq 30) &\approx \Phi\left(\frac{30 + 0.5 - 20}{3.65}\right) \\ &= \Phi(2.877) \\ &= 0.998 \end{aligned} \tag{71}$$

- **Sempre considerando 60 macchinari trovare un numero approssimato r , tale che la probabilità che più di r macchinari usino energia elettrica allo stesso tempo sia 0.1.**

Vogliamo cercare r tale che

$$P(X > r) = 0.1$$

Dunque procediamo semplicemente nel seguente modo

$$\begin{aligned} P(X > r) &= 1 - P(X \leq r) \\ &= 1 - \Phi\left(\frac{r + 0.5 - 20}{3.65}\right) \\ &\rightarrow 1 - \Phi\left(\frac{r + 0.5 - 20}{3.65}\right) = 0.1 \\ &\rightarrow -\Phi\left(\frac{r - 19.5}{3.65}\right) = 0.1 - 1 \\ &\rightarrow \Phi\left(\frac{r - 19.5}{3.65}\right) = -0.1 + 1 \\ &\rightarrow \Phi\left(\frac{r - 19.5}{3.65}\right) = 0.9 \\ &\rightarrow \frac{r - 19.5}{3.65} = \Phi^{-1}(0.9) \\ &\rightarrow r - 19.5 = \Phi^{-1}(0.9) \cdot 3.65 \\ &\rightarrow r = 19.5 + \Phi^{-1}(0.9) \cdot 3.65 \\ &\rightarrow r = 19.5 + 1.29 \cdot 3.65 \\ &\rightarrow r = 19.5 + 4.70 \\ &\rightarrow r = 24.2 \\ &\rightarrow r \approx 24 \end{aligned} \tag{72}$$