

Capitolo 2: Indici (Statistica Descrittiva)

Dispensa basata sugli appunti di Statistica, ottimizzata per l'esame open-book.

1. Sintesi Teorica e Concetti Chiave

Indici di Centralità

- **Media Campionaria:** È il "baricentro dei dati". Gode della proprietà per cui la somma degli scarti dalla media è zero. È poco robusta rispetto agli outliers (valori anomali).
- **Mediana Campionaria:** Il valore che divide il campione ordinato esattamente a metà (almeno il 50% $\leq$ e almeno il 50% $\geq$). Molto robusta. Se i dati sono in numero pari, si fa la media aritmetica dei due centrali.
- **Moda Campionaria:** Il dato che si presenta più frequentemente. Un campione può essere unimodale o multimodale.

Indici di Dispersione

- **Quantili:** Generalizzazione della mediana (che è il quantile 0.5). Dividono i dati in frazioni (es. percentili [0-100], decili [0-10], quartili [0-4]).
 - *Range Interquartile (IQR):* Differenza tra il terzo quartile (Q3) e il primo quartile (Q1).
- **Varianza Campionaria (s^2):** Misura la dispersione dei dati elevando al quadrato la distanza di ciascun punto dalla media (per evitare segni negativi).
- **Deviazione Standard Campionaria (s):** Radice quadrata della varianza. Riporta l'indice alla stessa unità di misura dei dati originali.
- **Coefficiente di Variazione:** Standardizza la deviazione standard dividendola per il valore assoluto della media. Utile per confrontare distribuzioni con scale di grandezza diverse.

Relazione, Eterogeneità e Concentrazione

- **Covarianza e Correlazione:** Misurano la relazione tra due variabili (campione bivariato). La correlazione di Pearson (r) varia tra -1 (indiretta perfetta) e 1 (diretta perfetta), e non dipende dall'unità di misura.
- **Indice di Gini (Eterogeneità):** Valuta quanto un campione è eterogeneo (0 = minima eterogeneità, tutti uguali; massimizzato quando le frequenze sono distribuite

equamente). Può essere normalizzato per assumere valori tra 0 e 1.

- **Entropia:** Alternativa a Gini basata sui logaritmi. Normalizzabile in bit (logaritmo in base 2).
- **Indice di Gini (Concentrazione):** Genera la Curva di Lorenz. Misura la disuguaglianza (es. distribuzione della ricchezza). 0 = equità perfetta, 1 = massima disuguaglianza (tutto a uno solo).

Trasformazioni e ANOVA

- **Traslazioni e Scalature:** Traslare i dati (+k) sposta media e mediana ma non altera la varianza. Scalare i dati (*k) altera tutto (la varianza viene moltiplicata per k^2).
- **Standardizzazione:** Permette di avere una scala comune sottraendo la media e dividendo per la deviazione standard.
- **ANOVA (Analysis of Variance):** Scompone la varianza totale (SS_T) nella somma della variabilità interna ai gruppi (SS_W) e della variabilità tra i gruppi (SS_B). Serve per testare differenze significative tra gruppi.

2. Formulario Essenziale

Metrica	Formula	Condizioni / Descrizione
Media Campionaria	$(1/n) \sum x_i$	Baricentro dei dati.
Varianza Campionaria (s^2)	$(1/(n-1)) \sum (x_i - \text{media})^2$	Spesso riscritta come $(1/(n-1)) (\sum x_i^2 - n \cdot \text{media}^2)$
Deviazione Standard (s)	$\sqrt{s^2}$	Stessa unità di misura dei dati originali.
Coeff. di Variazione (s^*)	$s / \text{media} $	Utile per confronti tra scale diverse.

Metrica	Formula	Condizioni / Descrizione
Covarianza	$(1/(n-1)) \sum (x_i - m_x)(y_i - m_y)$	Se ≥ 0 c'è correlazione diretta.
Coeff. di Pearson (r)	$\text{Cov}(x,y) / (s_x * s_y)$	Compreso tra $[-1, 1]$. Invariante alle unità.
Indice di Gini (Eterog.)	$1 - \sum f_j^2$	Eterogeneità max: $(k-1)/k$ (dove k = numero simboli).
Entropia (H)	$\sum f_j * \log(1/f_j)$	H normalizzato = $H / \log(k)$.
Standardizzazione (z)	$(v - \text{media}) / s$	Mappa i dati su scala standard.
Teorema ANOVA	$SS_T = SS_W + SS_B$	$SS_{\text{Total}} = SS_{\text{Within}} + SS_{\text{Between}}$

3. Esempi ed Esercizi Pratici

Esercizio 1: Indici di Centralità

Traccia: Dato il campione $C = \{4, 2, 8, 4, 6\}$, calcola Media, Mediana e Moda.

Soluzione:

- **Media:** $(4 + 2 + 8 + 4 + 6) / 5 = 24 / 5 = 4.8$.
- **Mediana:** Ordino il campione $\{2, 4, 4, 6, 8\}$. $N = 5$ (dispari), prendo il valore centrale al posto $(5+1)/2 = 3^\circ$ posto. Mediana = 4.
- **Moda:** Il valore che appare più spesso è 4 (frequenza assoluta 2). Moda = 4.

Esercizio 2: Indice di Eterogeneità di Gini

Traccia: Una scatola contiene 30 palline rosse, 30 palline verdi e 30 palline blu. Calcola l'indice di Gini per l'eterogeneità dei colori e normalizzalo.

Soluzione:

- Le categorie (k) sono 3. Il totale è 90.
- Le frequenze relative (f) per ciascun colore sono: $30/90 = 1/3$.
- **Indice di Gini (I):** $1 - [(1/3)^2 + (1/3)^2 + (1/3)^2] = 1 - (1/9 + 1/9 + 1/9) = 1 - 3/9 = 1 - 1/3 = 2/3 \approx 0.67$.
- Notiamo che questa è l'eterogeneità massima per $k=3$, pari alla formula teorica $(k-1)/k = (3-1)/3 = 2/3$.
- **Gini Normalizzato (I')**: $[k / (k-1)] * I = [3 / 2] * (2/3) = 1$. (Distribuzione perfettamente eterogenea, equiprobabile).

Esercizio 3: Trasformazioni

Traccia: Un campione ha Varianza $s^2 = 10$. Se moltiplico tutte le osservazioni per un fattore $\alpha = 3$, quale sarà la nuova Varianza?

Soluzione:

La varianza scala al quadrato rispetto al fattore di dilatazione/contrazione. Quindi la nuova varianza sarà: $s_{\text{nuova}}^2 = \alpha^2 * s^2 = 3^2 * 10 = 9 * 10 = 90$.