

Riassunto: Definizioni Generali di Statistica

Tommaso Giorgio Bianco

1 Sintesi Teorica e Concetti Chiave

1.1 I Caratteri Statistici

- **Qualitativo:** Misurazione effettuata scegliendo un'etichetta da un insieme di opzioni disponibili.
 - *Nominale:* Non possiedono un ordine o categorie intrinseche e non possono essere confrontati (es. colore dei capelli).
 - *Binario o Booleano:* Caso particolare nominale con due sole opzioni (es. genere, vero/falso, assenza/presenza).
 - *Ordinale:* Caratteri relazionabili con operatori di disuguaglianza come $<, =, >$ (es. livelli di soddisfazione, classifiche).
- **Quantitativo:** L'esito della misurazione e' una quantita' numerica. Sono valori scalari con un ordine definito e unita' di misura.
 - *Discreto:* Valori che ha senso enumerare singolarmente (es. data di nascita, oggetti venduti).
 - *Continuo:* Valori che ha senso rappresentare tramite intervalli (es. altezza, temperatura corporea).

1.2 Popolazione, Campione e Bias

- **Popolazione:** Insieme completo degli oggetti di studio (spesso troppo grande per un esame esaustivo).
- **Campione:** Sottogruppo rappresentativo utilizzato per apprendere informazioni dall'intera popolazione.
- **Campione Bivariato:** Sequenza di coppie di numeri tra i quali esiste una relazione (x_i, y_i) .
- **Bias:** Tendenza a deviare dal valore atteso, che introduce distorsioni nei risultati quando si pensa di aver campionato bene, ma in realta' non e' cosi'.

1.3 Valutazione dei Classificatori Binari

Le predizioni di un classificatore si confrontano con la realta' e si dividono in:

- **Veri Positivi (VP) e Veri Negativi (VN):** Predizioni corrette.
- **Falsi Positivi (FP) e Falsi Negativi (FN):** Predizioni errate.

Queste misure servono a calcolare le metriche di accuratezza del modello e a costruire la **Curva ROC** (Receiver Operating Characteristic), un grafico che ne quantifica le performance. L'**AUC** (Area Under the Curve) e' l'area sottesa alla ROC: assume valori tra 0 e 1, dove 1 rappresenta il classificatore ideale.

2 Formulario Essenziale

- **Frequenza Relativa:** Rapporto tra la frequenza assoluta e l'insieme dei dati:

$$f_{rel} = \frac{f}{n}$$

- **Media Pesata:**

$$\bar{x} = \frac{1}{n} \sum_{j=1}^m v_j f_j$$

- **Accuratezza:**

$$ACC = \frac{VP + VN}{TP + TN}$$

- **Sensibilita' (SENS):** Capacita' di trovare i casi positivi.

$$SENS = \frac{VP}{TP} = \frac{VP}{VP + FN}$$

- **Specificita' (SPEC):** Capacita' di trovare i veri negativi ed evitare i falsi positivi.

$$SPEC = \frac{VN}{TN} = \frac{VN}{VN + FP}$$

- **Coordinate Curva ROC:**

$$(1 - SPEC, SENS) = \left(\frac{FP}{FP + VN}, \frac{VP}{VP + FN} \right)$$

3 Esempi Pratici

3.1 Esempio 1: Tampone e Patogeno (Sensibilita' e Specificita')

Un tampone per la rivelazione di un patogeno con elevata **Sensibilita'** e' in grado di trovare il patogeno anche se presente in piccolissime quantita'. Al contrario, un tampone con elevata **Specificita'** rileva *solo e soltanto* quel patogeno, evitando i falsi positivi dovuti ad altri patogeni con RNA simile.

Se in una simulazione diagnostica si misurassero 60 Veri Positivi e 15 Falsi Negativi, la Sensibilita' del tampone verrebbe calcolata cosi':

$$SENS = \frac{VP}{VP + FN} = \frac{60}{60 + 15} = \frac{60}{75} = 0.8$$

3.2 Esempio 2: Classificatori Notevoli e Coordinate ROC

A seconda di come e' calibrato, un classificatore binario si posiziona diversamente sul grafico ROC:

- **Classificatore Costante Positivo (CP):** Prevede sempre positivo, beccando tutti i casi positivi ma sbagliando tutti i negativi.

$$SENS = \frac{VP}{TP} = 1, \quad SPEC = \frac{0}{TN} = 0$$

Posizione ROC: (1, 1).

- **Classificatore Ideale (CI):** Non sbaglia mai alcuna previsione.

$$SENS = \frac{VP}{TP} = 1, \quad SPEC = \frac{VN}{TN} = 1$$

Posizione ROC: (0, 1) nell'angolo in alto a sinistra.